

Демо на използвани модели при разработката на локален мултимодален AI агент

Vision модели + Tool Use + RAG

*

Предмет: „Откриване на знания в данни“
Изготвил: Симона Илиева, 3MI3400587 • ИИОЗ

1. Цел на демонстрацията

Проектът обработва неструктурирани файлове локално и извлича знания от тях.

Оценяване на отделните компоненти в локалния агент и резултатите върху приложените модели.

0 cloud

локално изпълнение

PDF / IMG / TXT

входни типове

5 метрики

оценяване

3

конфигурации

RAG настройки

1. Цел на демонстрацията


Проектът обработва неструктурирани файлове локално и извлича знания от тях.

5 метрики

оценяване


Component	Evaluation	Metrics
Semantic Search	Дали намира правилния chunk	Precision@k, Recall@k
RAG отговор	Дали отговорът е верен спрямо документа	Accuracy, faithfulness
Tool Use	Дали агентът избира правилния инструмент	Tool success rate
Vision модел	Дали правилно описва изображението	Human evaluation score
Производителност	Колко бързо работи локално	Response time, RAM usage

2. Архитектура на системата



3. Реализация на демото

Проектът включва Streamlit приложение, core агент и evaluation pipeline.



Основни технологии

Python + Streamlit
Ollama runtime
LLaVA / llama3.2-vision
pytesseract OCR
ChromaDB

Исходни артефакти

отговор чрез RAG
top-k chunks със score
време за обработка
precision/recall таблица
извод за най-добра конфигурация

4. Демонстрационен сценарий

Показва се целият път от файл до финален отговор и измервания.



Примерни въпроси към агента

„Какво е RAG?“
„Кои tools използва агентът?“
„Опиши архитектурата от изображението.“
„Извлечи сумата от фактурата.“


Какво доказва демото

- функционалност на агента
- правилен избор на tool
- работа с multimodal вход
- измеримо качество на retrieval

5. Тестови файлове и очаквани резултати

Оценката започва с фиксирани тестове и ръчно описан очакван резултат.

DEMO INVOICE / RECEIPT		
Item	Qty	Price
Notebook	2	12.00 BGN
USB Cable	1	8.50 BGN
Pen set	1	10.00 BGN
TOTAL: 42.50 BGN		
Payment: cash Date: 2026-06-29		



lecture_ai_agent.txt
RAG, Tool Use, Vision,
metrics

Пет тестови сценария

- T1: дефиниция за RAG
- T2: tools в агента
- T3: OCR на фактура
- T4: Vision описание на архитектура
- T5: извод за локално изпълнение

Очакван резултат

- правилен tool
- релевантни chunks
- коректна сума или описание
- кратък отговор върху документа

6. Методика за оценяване

Следвани са практики от Model Evaluation: тестове, очаквани резултати, метрики и сравнение.



Метрики

Response time
Precision@k
Recall@k
Tool Success Rate
Human Evaluation Score

Резултат

доказва работещ агент
показва качество, не само UI
позволява настройка на RAG параметрите
дава ясни констатации и изводи

7. Метрики и формули

Фокусът е върху retrieval, tool избор и качество на финалния отговор.

Precision@k
релевантни върнати chunks / всички
върнати chunks

Recall@k
намерени релевантни chunks /
всички релевантни chunks

Tool Success Rate
успешни tool извиквания / всички
извиквания

Response Time
извличане + retrieval + generation

Human Score 1–5
човешка оценка за вярност и
полезност


OCR / Vision качество
грешки при текст и описание на
изображение

Оценката е подходяща за AI агент, защото системата има няколко компонента: OCR, retrieval, LLM отговор и избор на tools.

8. Сравнение на RAG конфигурации

Аналогия с underfitting/overfitting: малко контекст vs. твърде много шум.

Конфигурация	Chunk size	Top-k	Интерпретация
A_under_context	200	3	Underfitting: липсва контекст
B_balanced	800	3	най-добър баланс
C_noisy_context	1600	5	повече шум и по-бавно



9. Резултати от оценяването

Конфигурация В постига най-добър баланс между precision, recall и време.

Precision и Recall



0.93

Avg Precision

1.00

Avg Recall

100%

Tool Success

5/5

Human Score


B_balanced: chunk size 800, top-k 3

Извод: средният chunk size осигурява достатъчно контекст без излишен шум.

9. Резултати от оценяването

Конфигурация B постига най-добър баланс между precision, recall и време

config	chunk_size	top_k	avg_precision	avg_recall	tool_success_rate	avg_human_score	avg_response_time	interpretation
A_under_context	200	3	0.53	0.53	1.00	3.60	12.70	Underfitting: малко контекст, непълни отговори.
B_balanced	800	3	0.93	1.00	1.00	5.00	15.60	Най-добър баланс: добра точност и умерено време.
C_noisy_context	1600	5	0.68	1.00	1.00	4.00	22.30	Overfitting: висок recall, но повече шум и по-бавно.



11. Констатации

Обобщение от демото и измерванията.

RAG подобрява точността, защото отговорите се базират на контекст от качения файл.

Vision/OCR компонентът е полезен при screenshots, диаграми и фактури.

Качеството зависи от резолюцията, шрифта и яснота на изображението.

Chunk size и top-k влияят силно върху precision, recall и време.

Локалното изпълнение пази данните, но изисква повече ресурси.

Най-силна конфигурация
B_balanced

Основен риск
твърде много шум при големи
chunks

Практическа стойност
локален knowledge discovery
асистент

12. Изводи

Какво показва проектът като система.

1

Локалните агенти са подходящи
за чувствителни документи.

2

Tool Use добавя реални
действия: OCR, parsing, search,
analysis.

3

RAG прави отговора проследим
към качения документ.

4

Оценяването трябва да включва
качество + време + ресурси.

5

Най-добрата настройка е баланс
между контекст и шум.

Финално заключение: проектът демонстрира реално приложение на multimodal AI, semantic retrieval и knowledge discovery в локална среда.